

# Statistique Mathématique

Examen — 5 mai 2021

*Durée : 3 heures. Documents et calculatrices interdits. Prenez soin de bien justifier vos réponses. Les trois parties sont indépendantes, mais il est conseillé de les traiter dans l'ordre. Les questions marquées d'un astérisque (\*) sont plus difficiles, il est normal qu'elles demandent plus d'efforts. Bonne chance !*

## Modélisation de paysage politique

Nous allons considérer dans cet examen la modélisation d'un paysage politique. Les citoyens d'un pays imaginaire se regroupent progressivement en partis politiques, formant à chaque instant  $n$  une *partition aléatoire* de  $\{1, \dots, n\}$ , l'ensemble des citoyens. On note cette partition aléatoire  $B_n$  : un parti politique est donc un ensemble de citoyens et  $B_n$  un ensemble de partis. Le nombre total de partis politiques au temps  $n$  est donc donné par  $|B_n|$ , le cardinal de  $B_n$ . Par exemple, pour  $n = 5$ , nous pourrions observer

$$B_5 = \{\{1, 3\}, \{4\}, \{2, 5\}\}, \quad |B_5| = 3.$$

On convient que  $B_1 = \{\{1\}\}$  et on note  $b \in B_n$  un élément de la partition  $B_n$ , c'est-à-dire un parti politique. Nous modélisons le processus d'évolution du paysage politique de la manière suivante : le citoyen  $n + 1$  rejoint chaque parti existant avec probabilité  $|b|/(n + \theta)$  ou crée son propre parti avec probabilité  $\theta/(n + \theta)$ , où  $\theta \in \mathbb{R}_+$  est un paramètre inconnu. Il est impossible pour un citoyen de quitter le parti auquel il appartient.

### Partie I : Préliminaires (4 points)

Dans cette première partie, nous établissons les propriétés fondamentales de notre modèle.

- I.1. Vérifiez que la loi de  $B_{n+1}$  sachant  $B_n$  est bien définie.
- I.2. Comment va évoluer  $(B_n)_{n \geq 1}$  si  $\theta = 0$ ? Si  $\theta = +\infty$ ? On appelle  $\theta$  le *coefficient d'ambition*. Cette nomenclature vous paraît-elle appropriée?
- I.3. Tracez sur un même graphique plusieurs trajectoires de  $|B_n|$  pour  $\theta = \theta_1$  avec  $\theta_1$  proche de 0. Répétez ce dessin pour un  $\theta = \theta_2 \gg \theta_1$ .
- I.4. Le modèle proposé vous paraît-il réaliste?

### Partie II : Étude d'un estimateur de $\theta$ (9 points)

On suppose dans cette partie que  $\theta > 0$ . Nous allons tenter d'estimer  $\theta$  à partir **d'une réalisation** de la suite  $B_1, \dots, B_n$ . Nous étudions dans un premier temps l'estimateur défini par  $\hat{\theta}_n^{(1)} := |B_n| / \log n$ .

- II.1. Montrez que  $|B_n|$  s'écrit  $\xi_1 + \dots + \xi_n$ , où  $\xi_1, \dots, \xi_n$  sont des variables aléatoires de Bernoulli indépendantes. On précisera le paramètre de chacune de ces Bernoulli.
- II.2. Déduire de la question II.1. que

$$\mathbb{E}[|B_n|] = \sum_{k=0}^{n-1} \frac{\theta}{\theta + k} \quad \text{et} \quad \text{Var}(|B_n|) = \sum_{k=1}^{n-1} \frac{\theta k}{(\theta + k)^2}.$$

- II.3. Montrez que  $\mathbb{E}[|B_n|] - \theta \log n = \mathcal{O}(1)$  lorsque  $n \rightarrow +\infty$ , où les constantes dans le  $\mathcal{O}$  peuvent dépendre de  $\theta$ . Que pouvez-vous dire du biais de  $\hat{\theta}_n$ ?

- II.4. Montrez que

$$\frac{\text{Var}(|B_n|)}{\theta \log n} = 1 + o(1).$$

- (\*) II.5. En utilisant les questions II.3. et II.4., montrez que l'estimateur  $\hat{\theta}_n^{(1)}$  est consistant.

II.6. En utilisant la même technique de preuve, peut-on montrer que  $\hat{\theta}_n^{(1)}$  est fortement consistant ?

II.7. On admet le résultat suivant :

$$\frac{|B_n| - \mathbb{E}[|B_n|]}{\sqrt{\text{Var}(|B_n|)}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$$

lorsque  $n \rightarrow +\infty$ . Montrez que  $\mathbb{E}[|B_n|]$  et  $\text{Var}(|B_n|)$  peuvent être remplacés par  $\theta \log n$  dans cette limite.

II.8. En utilisant la question précédente, proposez un intervalle de confiance asymptotique de niveau  $1 - \alpha$  pour  $\theta$ .

### Partie III : Micro-partis (7 points)

Dans cette dernière partie, on étudie la distribution des micro-partis (les partis politiques comptant un seul membre) et on en déduit un autre estimateur de  $\theta$ . On suppose toujours  $\theta > 0$  et on note  $C_n$  le nombre de micro-partis au temps  $n$ .

III.1. Décrire la loi de  $C_{n+1}$  conditionnellement à  $C_n$ .

III.2. Soit  $a \in \{1, \dots, n\}$ . Déduire de la question précédente que

$$\mathbb{E}[C_{n+1} \mid C_n = a] = \frac{a(n + \theta - 1) + \theta}{\theta + n}.$$

III.3. En utilisant la question précédente, montrez que

$$\mathbb{E}[C_n] = \frac{n\theta}{n + \theta - 1}.$$

(\*) III.4. Montrez que

$$\text{Var}(C_n) = \frac{n(n-1)(n-2+2\theta)\theta}{(n+\theta-2)(n+\theta-1)^2}.$$

III.5. Proposez un nouvel estimateur  $\hat{\theta}_n^{(2)}$  pour le paramètre  $\theta$ .

III.6. Quel estimateur conseillez-vous d'utiliser ? Justifiez votre réponse.