

## TD 2 : estimateurs

*Les questions marquées d'un astérisque (\*) sont facultatives.*

Dans tous les exercices, on commencera par soigneusement écrire le modèle statistique considéré.

**Exercice 1.** Soit  $(X_1, \dots, X_n)$  un  $n$ -échantillon de v.a. (variables aléatoires) i.i.d. (indépendantes et identiquement distribuées) suivant une loi normale de moyenne  $\mu$  et variance  $\sigma^2$  inconnues, qu'on cherche à estimer.

1. Calculer un estimateur du maximum de vraisemblance de  $(\mu, \sigma^2)$ . Calculer son biais. Calculer la variance de l'estimateur de  $\mu$ . Ces estimateurs sont-ils consistants ?
2. Calculer un estimateur de  $(\mu, \sigma^2)$  en utilisant la méthode des moments. Que constatez-vous ?

**Exercice 2.** Soit  $(X_1, \dots, X_n)$  un  $n$ -échantillon de v.a. i.i.d. suivant une loi uniforme sur  $[0, \theta]$ . On cherche à estimer  $\theta$ .

1. Calculer un estimateur du maximum de vraisemblance de  $\theta$ . Calculer sa fonction de répartition. En déduire sa densité, son biais et sa variance. Est-il consistant ?
2. Calculer un estimateur de  $\theta$  en utilisant la méthode des moments. Calculer son biais et sa variance. Est-il consistant ?

**Exercice 3.** Soit  $(X_1, \dots, X_n)$  un  $n$ -échantillon de v.a. i.i.d. suivant une loi exponentielle de paramètre inconnu.

1. Comparer les estimateurs de  $\theta$  obtenus par la méthode du maximum de vraisemblance et la méthode des moments.
2. On considère l'estimateur du maximum de vraisemblance. Est-il consistant ? Que peut-on dire de son biais ?

*On rappelle l'inégalité de Jensen : soit  $A$  un intervalle de  $\mathbb{R}$ ,  $\varphi : A \rightarrow \mathbb{R}$  une fonction convexe et  $X$  une variable aléatoire à valeurs dans  $A$ . Alors*

$$\mathbb{E}[\varphi(X)] \geq \varphi(\mathbb{E}[X]).$$

*De plus, si  $\varphi$  est strictement convexe, alors il y a égalité si et seulement si  $X$  est constante.*

**Exercice 4. (Unicité de l'estimateur du maximum de vraisemblance)**

1. Soient  $X_1, \dots, X_n$  une suite de v.a. i.i.d. uniformes sur  $[\theta, \theta + 1]$ . Calculer un estimateur du maximum de vraisemblance. Est-il unique ?
2. Soient  $X_1, \dots, X_n$  une suite de v.a. i.i.d. de loi de Laplace de paramètres  $(\mu, 1)$  (autrement dit, de densité  $x \mapsto \frac{\exp(-|x-\mu|)}{2}$ ). Montrer que la log-vraisemblance est dérivable sur  $\mathbb{R} \setminus \{X_1, \dots, X_n\}$  de dérivée

$$\mu \mapsto \#\{i \in \{1, \dots, n\} : X_i > \mu\} - \#\{i \in \{1, \dots, n\} : X_i < \mu\}.$$

En déduire que tout estimateur du maximum de vraisemblance de  $\mu$  est une médiane de l'échantillon  $(X_1, \dots, X_n)$ . L'estimateur du maximum de vraisemblance est-il unique ?

**Problème : régression non paramétrique (\*).** On observe des v.a.  $Y_1, \dots, Y_n$  qu'on suppose de la forme

$$Y_j = f\left(\frac{j}{n}\right) + \varepsilon_j$$

où  $\varepsilon_1, \dots, \varepsilon_n$  sont des v.a. i.i.d. gaussiennes de moyenne nulle et de variance connue  $\sigma^2$  et où  $f$  est une fonction inconnue de  $[0, 1]$  dans  $\mathbb{R}$  qu'on cherche à estimer. On fait l'hypothèse que  $f$  est  $(\alpha, L)$ -hölderienne pour  $\alpha \in (0, 1]$  et  $L > 0$ , autrement dit : pour tout  $x, y$ ,  $|f(x) - f(y)| \leq L|x - y|^\alpha$ .

1. Écrire le modèle statistique correspondant.

Comme ce modèle se prête mal à la méthode du maximum de vraisemblance, on procède plutôt comme suit. Soit  $D \geq 1$ . Pour tout  $i \in \{1, \dots, D\}$ , soit  $I_i = ]\frac{i-1}{D}, \frac{i}{D}]$ . On cherche un estimateur de  $f$  parmi les fonctions constantes sur chaque  $I_i$ . Pour simplifier, on suppose  $D|n$  et on note  $K = n/D$  le nombre de points de la forme  $j/n$  qui tombent dans  $I_i$  (pour un  $i$  fixé).

2. Écrire ce nouveau modèle statistique sous la forme d'un modèle paramétrique.

*Indication : les mesures de probabilité de ce modèle correspondent aux fonctions parmi lesquelles on cherche l'estimateur. Il n'est pas nécessaire que la vraie loi soit dans ce modèle.*

3. Montrer que l'estimateur du maximum de vraisemblance de  $f$  s'écrit

$$\hat{f}(x) = \sum_{i=1}^D \left( \frac{1}{K} \sum_{j=K(i-1)+1}^{Ki} Y_j \right) \mathbf{1}_{I_i}(x).$$

*Autrement dit,  $\hat{f}$  est constant sur chaque  $I_i$  égal à la moyenne des  $Y$  observés sur ce  $I_i$ .*

4. Calculer l'espérance de  $\hat{f}$ . Cet estimateur est-il sans biais ?
5. Notons  $\|g\|^2 = \int_{[0,1]} g(x)^2 dx$ . Montrer que l'erreur  $\mathbf{L}^2$  de cet estimateur se décompose suivant le compromis biais-variance

$$\mathbb{E}[\|\hat{f} - f\|^2] = \mathbb{E}[\|\hat{f} - \mathbb{E}[\hat{f}]\|^2] + \|\mathbb{E}[\hat{f}] - f\|^2.$$

En déduire que si  $D$  reste constant quand  $n \rightarrow \infty$ , cet estimateur n'est pas consistant.

6. Montrer qu'il existe une constante  $c \leq 1$  telle que le biais vérifie  $\|\mathbb{E}[\hat{f}] - f\|^2 \leq cL^2D^{-2\alpha}$ .
7. Montrer que la variance vérifie  $\mathbb{E}[\|\hat{f} - \mathbb{E}[\hat{f}]\|^2] \leq \sigma^2 D/n$ .
8. Quel choix de  $D$  proposez-vous ? En admettant que les réponses aux questions 5 à 7 restent vraies même si  $D$  ne divise pas  $n$ , quelle est la vitesse de convergence du risque de l'estimateur ?