

TD1 : Exercices de statistiques descriptives

A- Statistiques descriptives unidimensionnelles

Exercice 1 : Soit x une série statistique. Démontrer la formule de Koenig pour la variance :
$$s_x^2 = \overline{x^2} - \bar{x}^2.$$

Exercice 2 : Soit une série statistique de taille n , classée suivant la partition $[d_1, d_2[, \dots, [d_k, d_{k+1}[, \dots, [d_{m-1}, d_m[$. On note n_k, N_k, a_k respectivement l'effectif, l'effectif cumulé et l'amplitude de la classe $[d_k, d_{k+1}[$. Soit $[d_j, d_{j+1}[$ la première classe contenant au moins 50% des effectifs cumulés. Démontrer que l'on peut approcher la médiane par interpolation linéaire : $Me \approx d_j + \frac{n/2 - N_{j-1}}{n_j} \cdot a_j$. De façon analogue, trouver des formules approchées pour les premier et troisièmes quartiles.

Exercice 3 : Au poste de péage, on compte le nombre de voitures se présentant sur une période de 5mn. Sur 100 observations de 5mn, on obtient les résultats suivants :

Nombre de voitures	1	2	3	4	5	6	7	8	9	10	11	12
Nombre d'observations	2	8	14	20	19	15	9	6	2	3	1	1

- 1) Construire la table des fréquences et le diagramme en bâtons en fréquences de la série du nombre de voitures.
- 2) Calculer la moyenne et l'écart-type de cette série.
- 3) Déterminer la médiane, les quartiles et tracer le box-plot.
- 4) Etudier la symétrie de la série.

Exercice 4 : On donne la série unidimensionnelle suivante, correspondant à la répartition des entreprises du secteur automobile en fonction de leur chiffre d'affaire en millions d'euros.

chiffres d'affaires	moins de 0,25	[0,25 ; 0,5[[0,5 ; 1[[1 ; 2,5[[2,5 ; 5[[5 ; 10[
nombre d'entreprises	137	106	112	154	100	33

- a) Calculer le chiffre d'affaire moyen et l'écart-type de la série.
- b) Construire l'histogramme des fréquences
- c) Construire les deux polygones des fréquences cumulées
- d) Calculer la médiane et la proportion d'entreprises dont le chiffre d'affaire est supérieur à 3 millions d'euros.

Exercice 5 : La distribution des demandeurs d'emploi selon le sexe et la classe d'âge dans une localité est la suivante :

âge	Hommes	Femmes
[16 ;26[280	160
[26 ;40[310	360
[40 ;50[240	120
[50 ;60[420	530
[60 ;65[70	50

- Tracer les deux courbes de fréquences cumulées croissantes.
- Déterminer les quartiles de la variable X associant à chaque demandeur d'emploi masculin son âge. Même question pour les demandeurs d'emploi de sexe féminin.
- Conclusions.

B- Statistiques descriptives bidimensionnelles

Exercice 6 : On cherche à étudier la relation entre le nombre d'enfants d'un couple et son salaire. On dispose de la série bidimensionnelle suivantes :

Salaire en euros (Y)	Nombre d'enfants (X)
510	4
590	3
900	2
1420	1
2000	0
600	5
850	6
1300	7
2200	8

- Calculer le coefficient de corrélation linéaire entre ces deux variables statistiques.
Conclusion ?
- Un expert en démographie affirme que les deux caractéristiques sont indépendantes.
Qu'en pensez-vous ?

Exercice 7 : L'indice moyen d'un salaire a évolué de la façon suivante :

année	1	2	3	4	5	6	7
indice	165	176	193	202	222	245	253

- Représenter cette série statistique par un nuage de points.

- b) En utilisant la méthode des moindres carrées, calculer l'équation de la droite représentant l'indice en fonction de l'année.
 c) Comment pourrait-on prévoir l'indice à l'année 9 ?

Exercice 8 : Soit X une variable statistique qualitative à k modalités et Y une variable statistique quantitative. Chaque modalité de X définit une sous-population : celle des individus ayant cette modalité. On note n_j l'effectif correspondant à la modalité j de X , \bar{y}_j (resp. $s_j^2(y)$) la moyenne (resp. la variance) des valeurs de la variable Y pour les individus de la modalité j . Montrer que $s_Y^2 = s_E^2 + s_R^2$ où

$s_E^2 = \frac{1}{n} \sum_{j=1}^k n_j (\bar{y}_j - \bar{y})^2$ et $s_R^2 = \frac{1}{n} \sum_{j=1}^k n_j s_j^2(y)$. On les appelle respectivement variances inter et intra-catégories.

Exercice 9 : On observe le nombre d'enfants Y sur un ensemble de 12 individus répartis entre les sexes (variable X) :

F	3	4	5	4	2	5
H	10	7	6	3	4	2

- 1) Représenter graphiquement cette série.
- 2) Calculer les moyennes arithmétiques dans chaque classe
- 3) Calculer les variances inter et intra-catégories.
- 4) Calculer et interpréter le rapport de corrélation entre X et Y . Conclusion ?

Exercice 10 : Soient x et y deux séries statistiques de taille n . On note rx et ry les séries des rangs correspondantes.

a) Montrer que $\overline{rx} = \frac{n+1}{2}$.

b) Montrer que $s_{rx}^2 = \frac{n^2-1}{12}$.

c) En posant $d_i = rx_i - ry_i$, montrer que $2s(rx, ry) = s_{rx}^2 + s_{ry}^2 - \frac{1}{n} \sum_{i=1}^n d_i^2$.

d) En déduire l'expression du coefficient linéaire entre ces deux séries, appelé

coefficient de corrélation des rangs de Spearman : $r_s = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2-1)}$.

Exercice 11 : Dix échantillons de cidre ont été classés par ordre de préférence par deux gastronomes. On obtient les classements suivants :

A	1	2	3	4	5	6	7	8	9	10
B	3	1	4	2	6	5	9	8	10	7

- 1) Calculer le coefficient de corrélation des rangs de Spearman. Conclusion ?

- 2) Une autre façon d'évaluer le lien entre les rangs de deux séries consiste à utiliser le coefficient de corrélation des rangs de Kendall. Ce coefficient est défini par :

$$\tau = \frac{2S}{n(n-1)}, \text{ où } S \text{ est obtenue de la façon suivante : on considère tous les couples}$$

d'individus de la série. On note 1 si les individus i et j sont dans le même ordre pour les deux variables considérées (ici $a_i < a_j$ et $b_i < b_j$). On note -1 si les deux classements discordent (ici $a_i < a_j$ et $b_i > b_j$). S est la somme des valeurs obtenues pour les $\frac{n(n-1)}{2}$ couples distincts. Montrer que τ est compris entre -1 et

1 et qu'il est d'autant plus proche de 1 que les classements sont semblables.

Calculer τ pour les données dont on dispose.

Exercice 12 : On considère un échantillon de 797 étudiants d'une université ayant obtenu le DEUG. On étudie le lien entre l'âge d'obtention du Bac (variable Y), à 4 modalités (moins de 18 ans, 18 ans, 19 ans, plus de 19 ans), et la durée d'obtention du DEUG (variable X), à 3 modalités (2 ans, 3 ans, 4 ans). On a la table de contingence ci-dessous :

X	Y	Moins de 18 ans	18 ans	19 ans	Plus de 19 ans
2 ans		84	224	73	19
3 ans		35	137	75	27
4 ans		14	59	34	16

- 1) Déterminer le tableau des profils colonnes en pourcentage
- 2) Représenter graphiquement le diagramme en barre de ces profils
- 3) Déterminer le tableau des effectifs théoriques
- 4) Calculer l'indice du Chi2 et les contributions de chaque case. Conclusion ?