

# Travaux Dirigés

## • Méthode du maximum de vraisemblance MV (maximum likelihood ML) :

o Cette méthode permet de calculer, à partir d'un échantillon observé, la (les) meilleure(s) valeur(s) d'un paramètre d'une loi de probabilité.

o Le principe de la méthode MV : Si un phénomène  $X$  a été l'objet de  $n$  observations indépendantes  $x_1, x_2, \dots, x_n$  les unes des autres, sa loi de probabilité  $P(X = x)$  (dans le cas discret : loi binomiale, loi de Poisson) ou sa densité (en cas de loi continue, comme la loi normale) est une fonction  $f(x; \theta_1, \dots, \theta_n)$  où  $\theta_1, \dots, \theta_n$  sont les paramètres de la loi.

· Dans le cas discret : on définit la fonction de **MV** est la probabilité de l'échantillon observé en fonction des paramètres  $\theta = (\theta_1, \dots, \theta_n)$  :

$$\begin{aligned} L(x_1, x_2, \dots, x_n; \theta) &= P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n; \theta) \\ &= P_X(x_1, x_2, \dots, x_n; \theta), \end{aligned}$$

avec  $X = (X_1, X_2, \dots, X_n)$ .

· Dans le cas continu : on définit la fonction de **MV** est définie par

$$L(x_1, x_2, \dots, x_n; \theta) = P_X(x_1, x_2, \dots, x_n; \theta).$$

· On maximise la fonction  $L(x_1, x_2, \dots, x_n; \theta)$  sur l'ensemble des paramètres  $\theta$  pour trouver  $\hat{\theta}$  l'estimateur de **MV**,

$$\hat{\theta} = \arg \max_{\theta} L(x_1, x_2, \dots, x_n; \theta).$$

**Exercice 1.** Soit la variable aléatoire  $X \sim \mathcal{B}(n, p)$  et  $(X_1, X_2, \dots, X_n)$  un échantillon *i.i.d* de même loi que  $X$ .

- Calculer la fonction de **MV** de cette échantillon.
- Estimer le paramètre  $p$  de cette loi.

**Exercice 2.** Soit la variable aléatoire  $X \rightsquigarrow \mathcal{N}(m, \sigma)$  et  $(X_1, X_2, \dots, X_n)$  un échantillon i.i.d de même loi que  $X$ .

- Calculer la fonction de MV de cette échantillon.
- Estimer les paramètres de cette loi.

**Exercice 3.**

- Montrer les propriétés suivantes :

- 

$$OR(x, \tilde{x}) > 1 \iff P(Y = 1|X = x) > P(Y = 1|X = \tilde{x}).$$

- 

$$OR(x, \tilde{x}) = 1 \iff P(Y = 1|X = x) = P(Y = 1|X = \tilde{x}).$$

- 

$$OR(x, \tilde{x}) < 1 \iff P(Y = 1|X = x) < P(Y = 1|X = \tilde{x}).$$

- si  $P(Y = 1|X = x)$  et  $P(Y = 1|X = \tilde{x})$  sont très petits par rapport à 1, on peut faire l'approximation

$$OR(x, \tilde{x}) = \frac{P(Y = 1|X = x)}{P(Y = 1|X = \tilde{x})}.$$

- b) Quel est le meilleurs modèles parmi les trois modèles suivant :

- Modèle 1 : AIC = 51.09.
- Modèle 2 : AIC = 42.87.
- Modèle 3 : AIC = 43.10.

$$odds(x) = \frac{P(Y = 1|X = x)}{1 - P(Y = 1|X = x)}.$$

- L'odds ratio  $OR$  (**rapport des odds**) (**rapport des chances**) entre deux individus  $x$  et  $\tilde{x}$  est

$$OR(x, \tilde{x}) = \frac{odds(x)}{odds(\tilde{x})}.$$

**Exercice 4.** Données sur maladie coronarienne :

AGE : age.

CHD : diagnostic de maladie coronarienne.

$CHD \setminus Age$	$x = 1$ $(Age \geq 55)$	$x = 0$ $(Age < 55)$	Total
$y = 1$ (Yes)	21	22	43
$y = 0$ (No)	6	51	57
Total	27	73	100

- a) Quelle est la loi de la variable  $y = \text{"CHD"}$  ?
- b) Déterminer les paramètres  $y$ .
- c) Quelle est l'espérance de  $y$  ?
- d) Déterminer l'expression de la fonction reliant l'espérance de la variable  $y = \text{"CHD"}$  et la variable explicative  $x = \text{"Age"}$ .
- e) Calculer les "odds" de  $x = 1$  et de  $x = 0$ . Déduire "Odds Ratio"  $OR(x = 1, x = 0)$ .