

# Travaux Dirigés

**Exercice 1.** Dans le modèle de régression

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \epsilon = \beta_0 + \mathbf{X}^T \boldsymbol{\beta} + \epsilon,$$

- Déterminer les éléments de la matrice de design  $\mathbf{X}$ .
- Calculer le prédicteur linéaire  $\mathbf{X}^T \boldsymbol{\beta}$ .

**Exercice 2.**

- Utiliser la méthode des moindres carrés pour montrer que l'estimateur du vecteur  $\hat{\boldsymbol{\beta}}$  est donné par

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X} \mathbf{y}$$

- Calculer  $\sigma^2$  la variance de variable aléatoire Gaussienne  $\epsilon$ .

**Exercice 3.**

- Soit  $X \sim \mathcal{B}(p)$  "la loi de Bernoulli". Déterminer la loi de  $X$ .
- Calculer la moyenne et la variance de  $X$ .

**Exercice 4.**

- Soit  $X \sim \mathcal{B}(n, p)$  "la loi binomiale (ou multinomiale)". Déterminer la loi de  $X$ .
- Calculer la moyenne et la variance de  $X$ .

**Exercice 5.**

- Soit  $X \sim \mathcal{P}(\lambda)$  "la loi de Poisson". Déterminer la loi de  $X$ .
- Calculer la moyenne et la variance de  $X$ .

**Exercice 6.**

- Pour des raisons de santé publique, on s'intéresse à la concentration d'ozone  $O_3$  dans l'air (en microgrammes par millilitre). En particulier, on cherche à savoir s'il est possible d'expliquer le taux maximal d'ozone de la journée par la température  $T_{12}$  à midi. Les données sont :

$T_{12}$	23.8	16.3	27.2	7.1	25.1	27.5	19.4	19.8	32.2	20.7
$O_3$	115.4	76.8,	113.8	81.6,	115.4	125	83.6	75.2	136.8	102.8

- On cherche à expliquer la variable  $Y = O_3$  à partir de la variable  $X_1 = T_{12}$ .
- Ecrire le modèle de régression linéaire correspondant et déterminer la matrice de design.
- Représentez, à l'aide d'une graphe adapté, la relation entre la variable  $X_1$  et  $Y$ .
- Donner une estimation des différents paramètres du modèle.
- Calculer le coefficient de détermination  $r^2 = \rho_{(X_1, Y)}$ , avec

$$\rho_{(X_1, Y)} = \frac{\text{cov}(Y, X_1)}{\sqrt{\text{Var}\{Y\}} \sqrt{\text{Var}\{X_1\}}}$$

- Importer les données sous R et étudier l'effet de la variable  $X_1$  sur la variable  $Y$ .

**Exercice 7.** Les données utilisées sont le taux de décès par attaque cardiaque chez les hommes de 55 à 59 ans dans différents pays.

$$Y = (124, 49, 181, 4, 22, 152, 75, 54, 43, 41, 17, 22, 16, 10, 63, 170, 125, 15, 221, 171, 97, 254)$$

$$X_1 = (33, 31, 38, 17, 20, 39, 30, 29, 35, 31, 23, 21, 8, 23, 37, 40, 38, 25, 39, 33, 38, 39)$$

$$X_2 = (8, 6, 8, 2, 4, 6, 7, 7, 6, 5, 4, 3, 3, 3, 6, 8, 6, 4, 7, 7, 6, 8)$$

$$X_3 = (81, 55, 80, 24, 78, 52, 52, 45, 50, 69, 66, 45, 24, 43, 38, 72, 41, 38, 52, 52, 66, 89)$$

Les variables sont les suivantes :

- $Y$  :  $100 * \log(\text{nombre de décès par crise cardiaque pour 100000 hommes de 55 à 59 ans})$ .
- $X_1$  : nombre de téléphones pour 1000 habitants.
- $X_2$  : calories grasses en pourcentage du total de calories.
- $X_3$  : calories protéines animales en pourcentage du total de calories.
- a) On cherche tout d'abord à expliquer la variable  $Y$  à partir de la variable  $X_1, X_2$  et  $X_3$ .
  - Ecrire le modèle de régression linéaire correspondant et déterminer la matrice de design.
  - Représentez, à l'aide d'une graphe adapté, la relation entre les variables  $X_1$  et  $Y$ ,  $X_2$  et  $Y$ ,  $X_3$  et  $Y$ .
  - Donner une estimation des différents paramètres du modèle.
  - Importer les données sous R et étudier l'effet des variables  $X_1, X_2$  et  $X_3$  sur la variable  $Y$ .